Gestión de Costos Operativos en un Proyecto de Construcción

Prueba Técnica – Científico de Datos Senior

Andrés Fernando Gómez Rojas

Data Scientist

Abril 2026

Contents

1 Explicación del caso **2**

2 Supuestos **2**

3 Formas de resolver el caso y opción tomada **2**

4 Resultados del análisis de los datos y los modelos **3**
4.1 Limpieza de datos . . . 3
4.2 Análisis exploratorio . . . 3
4.2.1 Correlaciones . . . 3
4.2.2 Multicolinealidad y anomalías . . . 3
4.2.3 Impacto del COVID . . . 3
4.3 Modelamiento . . . 4
4.3.1 Ronda 1: modelos base . . . 4
4.3.2 Ronda 2: con y sin interacciones . . . 4
4.3.3 Ronda 3: optimización . . . 4
4.3.4 Feature importance . . . 5
4.3.5 Análisis de residuos . . . 5
4.3.6 Prophet . . . 5
4.3.7 Validación distribucional . . . 7

5 Proyección de costos y horizonte de predicción **8**
5.1 Horizonte . . . 8
5.2 Estrategia de proyección . . . 8
5.3 Resultados mensuales . . . 10

6 Agente de IA **11**
6.0.1 IA convencional vs agente de IA . . . 11

7 Arquitectura propuesta en la nube (AWS) **11**
7.1 Arquitectura en mejora . . . 12

8 Futuros ajustes o mejoras **12**

9 Apreciaciones y comentarios del caso **13**

Explicación del caso

Una empresa del sector constructor necesita anticipar los costos de adquisición de dos tipos de equipos críticos durante la fase de planificación de un proyecto. Históricamente estos costos han presentado desviaciones presupuestales que la empresa no ha logrado controlar, y la gerencia sospecha que existe una relación entre los precios de ciertas materias primas del mercado y el costo final de los equipos.

El objetivo del análisis es doble: primero, identificar cuáles de las tres materias primas disponibles (X, Y, Z) realmente explican el comportamiento de cada equipo, descartando las que constituyen ruido; y segundo, construir un modelo que permita proyectar costos futuros con la incertidumbre asociada, de manera que la empresa pueda planificar su presupuesto con mayor precisión.

Los datos proporcionados cubren desde enero de 2010 hasta agosto de 2023, con registros diarios de precios para las tres materias primas y los dos equipos. Adicionalmente se dispone de series individuales de cada materia prima con rangos temporales más amplios, lo cual resulta relevante para la proyección.

Supuestos

Para el desarrollo del análisis se asumieron las siguientes condiciones:

La relación entre materias primas y equipos es contemporánea, es decir, el precio del equipo en un día dado depende del precio de las materias primas en ese mismo día o días muy cercanos, no de meses atrás. Esto se validó con el análisis de rezagos.

Los datos proporcionados representan precios de mercado reales y no contienen errores de registro más allá de los problemas de formato ya identificados (separadores, orden de columnas, formatos de fecha).

El comportamiento futuro de las materias primas seguirá patrones estadísticamente consistentes con el histórico, lo cual es una limitación inherente a cualquier modelo predictivo. Se proyectó a un horizonte de 6 meses precisamente para mitigar el riesgo de extrapolar demasiado lejos.

No se conoce la identidad real de las materias primas X, Y y Z, por lo que el análisis es puramente estadístico sin incorporar conocimiento de dominio específico sobre commodities.

Formas de resolver el caso y opción tomada

El problema admite varias aproximaciones. Una primera sería tratar cada equipo como una serie de tiempo pura y modelar su evolución temporal sin considerar las materias primas, usando métodos como ARIMA o suavizamiento exponencial. Esta aproximación ignoraría la información explícita que proporcionan los precios de insumos.

Una segunda aproximación sería construir modelos de regresión que usen las materias primas como variables explicativas, asumiendo que el costo del equipo es función directa de los precios de sus insumos. Esto es más interpretable y aprovecha la estructura del problema.

Una tercera opción combina ambas: usar un modelo de series de tiempo con variables exógenas, capturando tanto la dinámica temporal propia del equipo como la influencia de las materias primas.

La opción adoptada fue explorar las tres aproximaciones y compararlas rigurosamente. Se entrenaron modelos de regresión lineal (Lasso, Ridge, ElasticNet), modelos no lineales (Random Forest, XGBoost, Gradient Boosting) y Prophet como modelo temporal con regresores. La

comparación se hizo con split temporal 80/20 y validación cruzada temporal para respetar la naturaleza secuencial de los datos.

Resultados del análisis de los datos y los modelos

Limpieza de datos

Los archivos presentaron varias particularidades que fue necesario corregir antes del análisis. El archivo Y.csv usaba punto y coma como separador, coma europea para decimales, fechas en formato DD/MM/AAAA y un carácter BOM invisible al inicio. El archivo Z.csv tenía las columnas invertidas (Price, Date en lugar de Date, Price). El archivo X.csv estaba ordenado de más reciente a más antiguo.

Tras la limpieza se verificó la consistencia cruzada entre los archivos individuales y el histórico consolidado: las 3,530 fechas en común mostraron diferencia cero entre ambas fuentes.

Análisis exploratorio

El análisis exploratorio abarcó estadísticas descriptivas, test de normalidad, descomposición temporal, pruebas de estacionariedad, análisis de correlación, detección de anomalías, causalidad de Granger, multicolinealidad y feature engineering, entre otros.

Las estadísticas descriptivas muestran que las cinco variables de precio tienen distribuciones no normales (Shapiro-Wilk y Jarque-Bera rechazan en todos los casos) con diferentes grados de asimetría. Price_Z presenta la mayor kurtosis (1.99), indicando colas más pesadas.

Ninguna de las series es estacionaria en niveles (Dickey-Fuller con p-values superiores a 0.10 en todos los casos), pero todas se vuelven estacionarias en primera diferencia (p-values de 0.0). Esto es consistente con el comportamiento típico de series de precios.

Correlaciones

El hallazgo central del análisis es la intensidad de las correlaciones entre materias primas y equipos. Price_Y muestra una correlación de Pearson de 0.9966 con el Equipo 1, y Price_Z de 0.9828 con el Equipo 2. Price_X tiene correlación moderada con ambos equipos (alrededor de 0.53). Las correlaciones de Spearman confirman estos resultados, indicando que la relación es esencialmente lineal.

La causalidad de Granger confirmó que todas las materias primas causan en sentido de Granger a ambos equipos. Y y Z lo hacen desde lag 1 con p-values de cero, mientras que X requiere lags más largos (lag 5 para Equipo 1, lag 2 para Equipo 2) para mostrar significancia.

Multicolinealidad y anomalías

El VIF reveló multicolinealidad severa entre Y (58.8) y Z (62.6), lo que motivó el uso de modelos con regularización. Price_X presenta VIF moderado (13.96).

En cuanto a anomalías, Price_X no presenta valores atípicos por ninguno de los tres métodos utilizados (IQR, Z-score, Isolation Forest). Las demás variables muestran anomalías que corresponden principalmente a picos de precios durante periodos de alta volatilidad.

Impacto del COVID

La segmentación por periodos mostró que las correlaciones entre materias primas y equipos se mantienen estables incluso durante el COVID. Y-Equipo 1 se mantiene por encima de 0.995 en

los tres periodos. La única relación que cambia significativamente es X-Equipo 1, que pasa de 0.72 pre-COVID a −0.018 post-COVID, indicando que X perdió su capacidad predictiva para ese equipo en el periodo reciente.

Modelamiento

Ronda 1: modelos base

Se entrenaron siete modelos con parámetros por defecto usando solo las tres materias primas como features. Los resultados muestran una clara separación entre modelos lineales y tree-based:

Table 1: Mejores resultados Ronda 1 – Price_Equipo1

Modelo	R^2 Train	R^2 Test	RMSE Test	MAPE Test (%)
Linear Regression	0.9927	0.9913	10.32	1.51
Ridge	0.9927	0.9913	10.33	1.51
Lasso	0.9926	0.9911	10.43	1.52
Random Forest	0.9924	0.6946	61.22	5.45
XGBoost	0.9943	0.6672	63.91	5.73

Los modelos tree-based muestran un gap train-test de 0.30 puntos en R^2, lo que indica sobreajuste claro. Esto se debe a que el periodo de test coincide con el post-COVID, donde el régimen de precios cambió. Los modelos lineales, al ser más simples, generalizan mucho mejor.

Ronda 2: con y sin interacciones

Se crearon 33 features derivadas incluyendo retornos porcentuales, promedios móviles, rezagos, volatilidades, ratios e interacciones entre materias primas. Los modelos se probaron con y sin estas features adicionales.

El resultado fue que las features derivadas no mejoran significativamente los modelos lineales para este problema. La razón es clara: la relación entre materias primas y equipos es tan fuerte y lineal que las transformaciones adicionales no aportan información nueva.

Ronda 3: optimización

Se optimizaron los hiperparámetros de los modelos lineales con GridSearchCV y TimeSeriesSplit de 5 folds. Los tree-based se dejaron con configuraciones conservadoras sin grid search dado su sobreajuste persistente.

Table 2: Resultados finales – Mejores modelos por equipo

Target	Modelo	R^2 Test	RMSE Test	MAE Test	MAPE (%)
Equipo 1	Lasso (α=0.1)	0.9913	10.31	8.86	1.51
Equipo 1	Prophet	0.9910	10.48	8.94	1.52
Equipo 2	Lasso (α=0.1)	0.9852	19.36	16.60	1.51
Equipo 2	Prophet	0.9851	19.39	16.67	1.51

Lasso y Prophet están prácticamente empatados. La diferencia en R^2 es de 0.0003 para Equipo 1 y 0.0001 para Equipo 2, lo cual no es estadísticamente significativo.

Feature importance

El análisis de coeficientes del Lasso confirma los hallazgos del EDA. Para Equipo 1, Price_Y domina con un coeficiente absoluto de 85.4, seguido de lejos por Price_X con 5.4. Para Equipo 2, Price_Z domina con 87.8, seguido por Price_Y con 35.4.

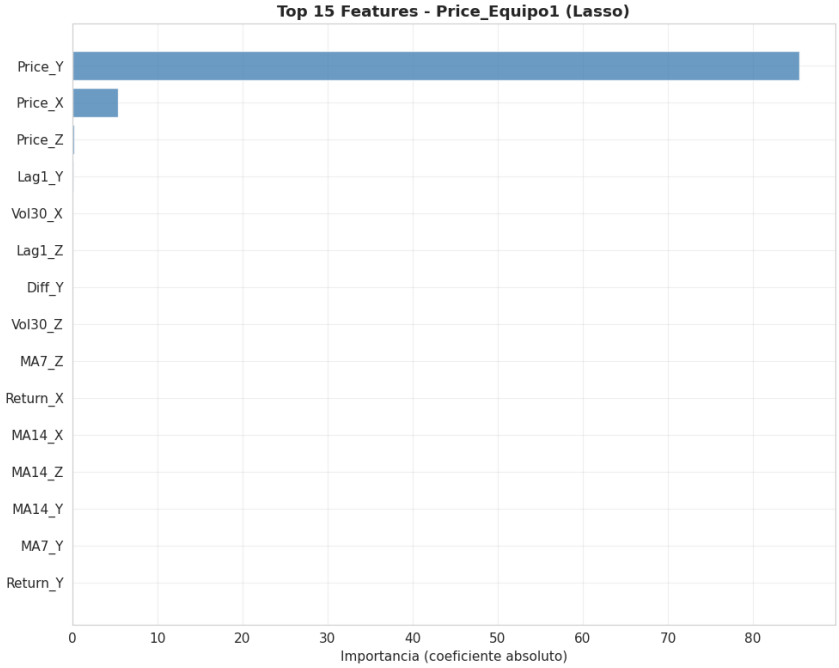

Figure 1: Importancia de features – Lasso para Equipo 1

Análisis de residuos

Los residuos de ambos modelos tienen media cercana a cero (0.22 para Equipo 1, 0.27 para Equipo 2) y no presentan autocorrelación significativa según el test de Ljung-Box (p-values de 0.89 y 0.14 respectivamente). Sin embargo, los residuos no son normales según Shapiro-Wilk, lo que sugiere que existen patrones no capturados por el modelo lineal, aunque su magnitud es pequeña respecto a la señal.

Prophet

Prophet se configuró con estacionalidad anual, changepoint_prior_scale de 0.05, e intervalos de confianza al 95%. Las materias primas se incorporaron como regresores externos.

El modelo detectó 25 changepoints en los datos de entrenamiento. La cobertura del intervalo de confianza sobre los datos de test fue del 84.3% para Equipo 1 y 86.6% para Equipo 2, lo cual está ligeramente por debajo del 95% nominal. Esto indica que la incertidumbre real es algo mayor a la estimada por el modelo.

Figure 2: Prophet – Equipo 1: ajuste en train y predicción en test con IC 95%

Figure 3: Prophet – Equipo 2: ajuste en train y predicción en test con IC 95%

Validación distribucional

Se aplicó el test de Kolmogorov-Smirnov para comparar la distribución de las predicciones contra los valores reales en el conjunto de test. Los resultados son favorables: para Equipo 1, KS statistic = 0.033 con p-value = 0.845; para Equipo 2, KS statistic = 0.020 con p-value = 0.999. En ambos casos no se rechaza la hipótesis de que las predicciones provienen de la misma distribución que los datos reales.

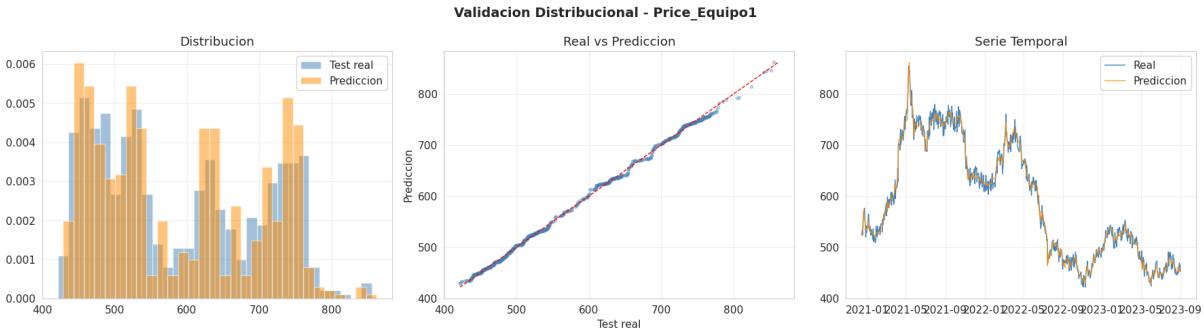

Figure 4: Validación distribucional – Equipo 1

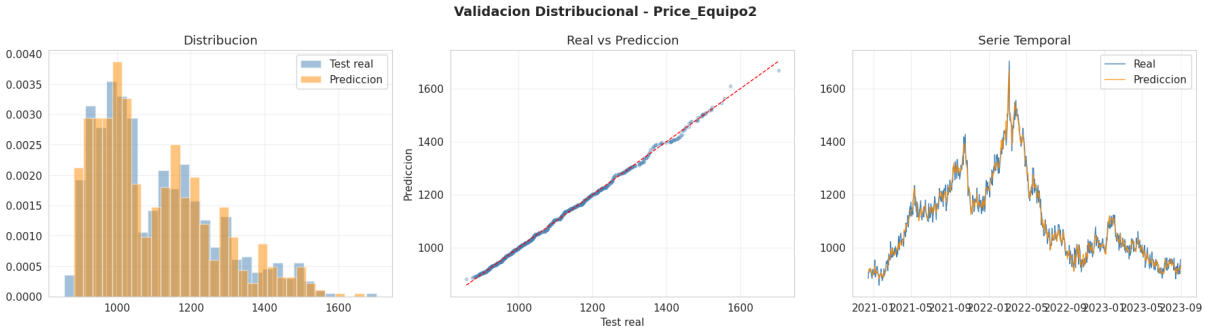

Figure 5: Validación distribucional – Equipo 2

Proyección de costos y horizonte de predicción

Horizonte

Se eligió un horizonte de 6 meses (septiembre 2023 a febrero 2024). Esta decisión se justifica porque Price_X tiene datos reales disponibles hasta abril 2024, pero Price_Y y Price_Z deben ser proyectados con Prophet, y la incertidumbre crece con cada mes adicional. Seis meses es un horizonte razonable para la planificación financiera de un proyecto de construcción.

Estrategia de proyección

Para proyectar los costos de los equipos fue necesario primero proyectar las materias primas que no tienen datos futuros. Price_X se usó con sus datos reales (disponibles hasta abril 2024). Price_Y y Price_Z se proyectaron con Prophet sobre sus series históricas individuales. Luego, estos valores proyectados se alimentaron al modelo de equipos para obtener las estimaciones finales.

Se usaron dos modelos en paralelo: Prophet como modelo principal (porque ofrece intervalos de confianza nativos) y Lasso como validación cruzada.

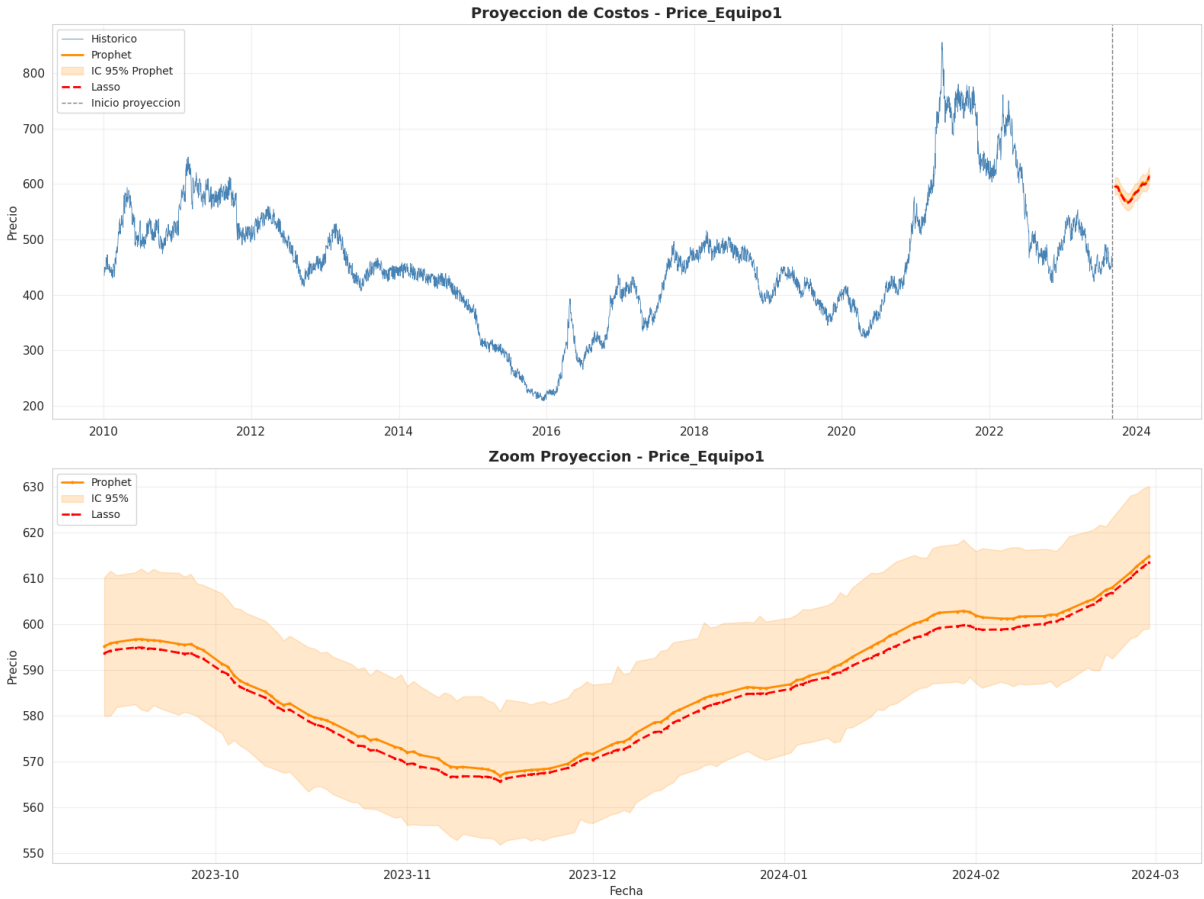

Figure 6: Proyección de costos – Equipo 1: histórico + proyección con IC 95%

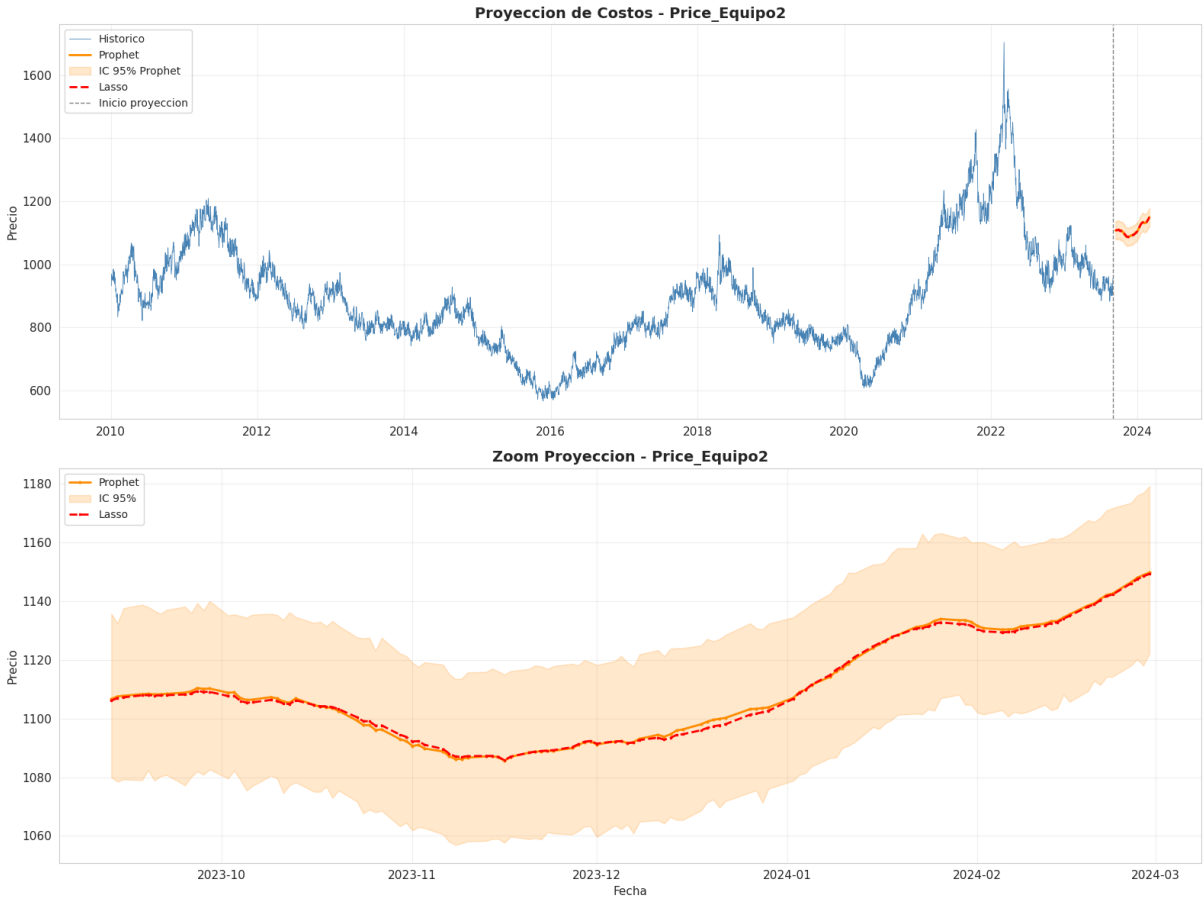

Figure 7: Proyección de costos – Equipo 2: histórico + proyección con IC 95%

Resultados mensuales

Table 3: Proyección mensual – Equipo 1

Mes	Prophet	IC Inferior	IC Superior	Lasso
Sep 2023	595.85	580.85	610.83	594.04
Oct 2023	581.04	565.81	596.00	579.33
Nov 2023	569.35	554.21	584.28	567.76
Dic 2023	580.45	565.42	595.42	578.68
Ene 2024	595.70	580.66	610.51	593.39
Feb 2024	605.13	590.13	620.20	603.47

Table 4: Proyección mensual – Equipo 2

Mes	Prophet	IC Inferior	IC Superior	Lasso
Sep 2023	1108.65	1080.11	1137.11	1108.01
Oct 2023	1102.76	1074.14	1131.33	1102.87
Nov 2023	1088.58	1059.97	1117.07	1089.03
Dic 2023	1096.89	1067.67	1124.70	1095.72
Ene 2024	1123.53	1095.28	1151.98	1123.34
Feb 2024	1137.21	1108.49	1165.40	1136.60

La concordancia entre Prophet y Lasso es notable: la diferencia promedio es menor a 2 unidades monetarias en ambos equipos, lo que refuerza la confianza en las proyecciones. El ancho del intervalo de confianza se mantiene estable a lo largo del horizonte (~30 para Equipo 1, ~57 para Equipo 2), representando aproximadamente un 5.1% del precio proyectado.

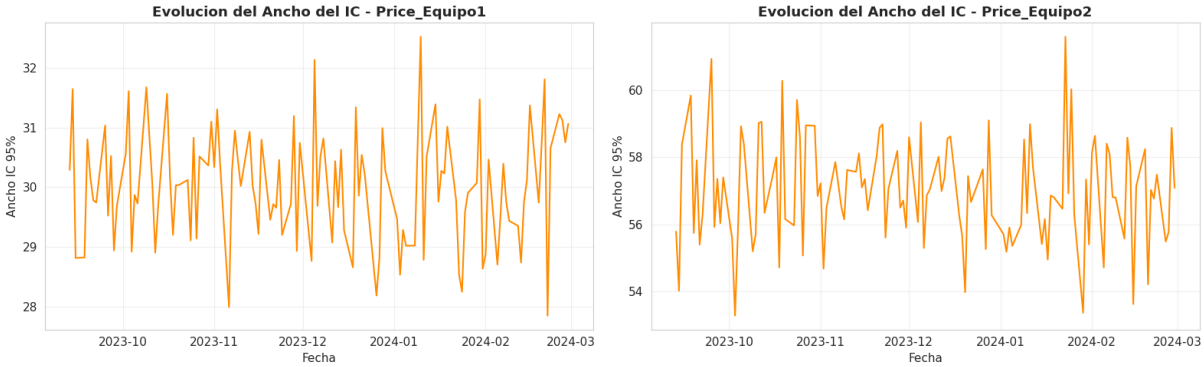

Figure 8: Evolución del ancho del intervalo de confianza en el horizonte de proyección

Agente de IA

Se desarrolló un agente conversacional que permite al evaluador consultar los resultados del análisis de forma interactiva. El agente utiliza Claude (Anthropic) a través de Amazon Bedrock y cuenta con nueve herramientas (tools) que consultan los resultados almacenados en S3.

Las herramientas cubren consultas sobre el EDA (estadísticas, correlaciones, anomalías, estacionariedad), los modelos (métricas, comparación, residuos, feature importance), Prophet (changepoints, componentes, intervalos), las proyecciones (costos mensuales, incertidumbre), la segmentación COVID y la volatilidad.

El agente mantiene memoria conversacional dentro de cada sesión, lo que permite hacer preguntas de seguimiento como "y los intervalos de esa proyección que me dijiste?" sin necesidad de repetir el contexto.

IA convencional vs agente de IA

Un sistema de IA convencional es un modelo que recibe datos de entrada y produce una salida: predice, clasifica o genera. Lasso y Prophet son ejemplos: reciben precios de materias primas y devuelven un precio estimado de equipo. No toman decisiones, no usan herramientas, no interactúan con su entorno.

Un agente de IA es un sistema autónomo que percibe su entorno (la pregunta del usuario), razona sobre qué acción tomar, selecciona y ejecuta herramientas (consultar datos, ejecutar modelos), y genera una respuesta integrada. El agente desarrollado en este proyecto es un ejemplo concreto: recibe una pregunta, decide cuál de las nueve herramientas usar, consulta los datos en S3, y construye una respuesta coherente. Los conceptos clave que lo diferencian de un modelo simple son autonomia en la toma de decisiones, uso de herramientas externas, memoria conversacional y capacidad de acción.

Arquitectura propuesta en la nube (AWS)

La solución se desplegó sobre cuatro servicios principales de AWS en la región us-east-2 (Ohio):

Amazon S3 almacena los datos crudos, los datos procesados, los resultados del EDA y modelamiento como archivos JSON, los modelos serializados y las proyecciones. El bucket se organiza en carpetas lógicas (datos_crudos, datos_procesados, eda_resultados, modelos, predicciones).

Amazon SageMaker se usó para el desarrollo y entrenamiento. Los notebooks de limpieza, EDA, modelamiento y predicciones se ejecutaron en una instancia de SageMaker con acceso directo a S3 mediante IAM roles. MLflow se usó localmente para el tracking de experimentos.

Amazon Bedrock proporciona acceso al modelo de lenguaje Claude Sonnet para el agente conversacional. El agente se conecta a través del SDK de Bedrock usando el inference profile de la región.

Amazon EC2 (t2.xlarge, Ubuntu 24.04) aloja la aplicación Streamlit que sirve como interfaz del agente. La instancia tiene acceso a S3 y Bedrock mediante un IAM role con los permisos necesarios.

Arquitectura en mejora

Para una implementación en producción se recomienda incorporar servicios adicionales que mejoren la escalabilidad, automatización y robustez:

AWS Lambda para ejecutar las predicciones bajo demanda sin mantener un servidor activo. Cada vez que se requiera una proyección, una función Lambda carga el modelo desde S3, ejecuta la predicción y devuelve el resultado. Esto elimina el costo de tener un EC2 corriendo permanentemente.

Amazon DynamoDB o **Amazon RDS** como base de datos para almacenar los resultados de forma estructurada en lugar de archivos JSON planos. DynamoDB sería adecuado por su baja latencia y esquema flexible; RDS si se requieren consultas SQL complejas.

AWS Step Functions para orquestar el pipeline completo de forma automatizada: ingesta de datos nuevos, limpieza, reentrenamiento del modelo, generación de proyecciones y actualización de los resultados del agente.

Amazon API Gateway delante de las funciones Lambda para exponer las herramientas del agente como endpoints REST seguros y escalables.

Amazon EventBridge para disparar el reentrenamiento de forma periódica o cuando se detecten nuevos datos en el bucket de S3.

Amazon CloudWatch para monitoreo, alertas y detección de degradación del modelo en el tiempo (model drift).

Futuros ajustes o mejoras

Hay varios ejes de mejora que se podrían explorar con más tiempo. Incorporar pruebas de cointegración (Engle-Granger o Johansen) para determinar si las series se mueven juntas en el largo plazo, lo que permitiría usar modelos de corrección de errores que son teóricamente más sólidos para series no estacionarias relacionadas.

Explorar modelos GARCH para capturar la heterocedasticidad condicional observada en los clusters de volatilidad, especialmente durante periodos de crisis. Esto mejoraría la estimación de intervalos de confianza.

Implementar un sistema de monitoreo de drift que detecte cuándo las relaciones entre materias primas y equipos cambian, disparando un reentrenamiento automático. La pérdida de relación entre X y Equipo 1 en el post-COVID es un ejemplo de este tipo de cambio de régimen.

Agregar búsqueda web al agente para complementar el análisis con contexto de mercado (tendencias de precios, noticias del sector, indicadores económicos), aunque esto depende de conocer la identidad real de las materias primas.

Implementar memoria persistente en el agente para que acumule conocimiento de las consultas del equipo financiero y mejore sus respuestas con el tiempo.

Apreciaciones y comentarios del caso

El caso está bien diseñado para evaluar competencias de ciencia de datos a nivel senior. La inclusión de problemas de formato en los archivos (separadores, columnas invertidas, formatos de fecha) es un buen test de atención al detalle en la etapa de limpieza.

Las correlaciones extremadamente altas entre las materias primas y los equipos hacen que el problema de predicción sea "fácil" en términos de métricas, pero el reto real está en la interpretación y comunicación de resultados, la selección correcta de modelos (evitando sobreajustar con modelos complejos cuando uno simple funciona mejor), y la construcción de una solución end-to-end que incluya proyección con incertidumbre.

Un hallazgo relevante es que los modelos tree-based, que suelen dominar en competencias de ML, aquí fracasan frente a una regresión lineal simple. Esto refuerza la importancia de entender los datos antes de elegir el modelo: cuando la relación es fundamentalmente lineal y el régimen de test difiere del de entrenamiento, la simplicidad gana.